

DPG和LQR简化版

详细版在这：[📖 DPG确定性策略梯度法和LQR控制的联系](#)

在确定性策略强化学习框架下，针对线性系统 $x_{k+1} = Ax_k + Bu_k$ 和二次奖励函数 $r_k = x_k^\top Qx_k + u_k^\top Ru_k$ ，价值函数与状态值函数的关系及贝尔曼方程推导如下：

1. 价值函数与状态值函数的关系

在确定性策略 $u_k = \mu(x_k)$ 下，状态值函数 $v_\mu(x_k)$ 与动作值函数 $q_\mu(x_k, u_k)$ 满足：

$$v_\mu(x_k) = \max_{u_k} q_\mu(x_k, u_k = \mu(x_k)) ; \text{ 当 } u_k \text{ 被选定下来等于 } u_k^{opt} \text{ 之后,}$$
$$v_\mu(x_k) = q_\mu(x_k, u_k^{opt} = \mu^{opt}(x_k))$$

这一关系源于确定性策略的特性：状态 x_k 的动作唯一由策略 μ 决定，因此状态值等于该策略下最优动作对应的动作值。

2. 贝尔曼方程的推导

动作值函数 $q_\mu(x_k, u_k)$ 的贝尔曼方程为：

$$q_\mu(x_k, u_k) = r_k + \gamma \cdot q_\mu(x_{k+1}, \mu(x_{k+1}))$$

其中：

- $r_k = x_k^\top Qx_k + u_k^\top Ru_k$ 是即时奖励；
- γ 为折扣因子（若未指定，默认为 1）；
- $x_{k+1} = Ax_k + Bu_k$ 是下一状态；
- $\mu(x_{k+1})$ 是策略在下一状态选择的动作。

代入状态值函数关系 $v_\mu(x_{k+1}) = q_\mu(x_{k+1}, \mu(x_{k+1}))$ ，可得：

$$q_\mu(x_k, u_k) = r_k + \gamma \cdot v_\mu(x_{k+1})$$

进一步，状态值函数 $v_\mu(x_k)$ 的贝尔曼方程为：

$$v_\mu(x_k) = q_\mu(x_k, \mu(x_k)) = \underbrace{x_k^\top Qx_k + \mu(x_k)^\top R\mu(x_k)}_{\text{即时奖励}} + \gamma \cdot v_\mu(x_{k+1})$$

3. 梯度计算与策略优化

在确定性策略梯度（DPG）算法中，目标是通过梯度上升最大化长期奖励。价值函数的梯度为：

$$\nabla_\theta v_\mu(x_k) = \nabla_\theta \mu(x_k) \cdot \nabla_a q_\mu(x_k, a) \Big|_{a=\mu(x_k)}$$

其中 θ 是策略参数。通过时序差分误差更新价值函数：

$$\delta_k = r_k + \gamma \cdot q_\mu(x_{k+1}, \mu(x_{k+1})) - q_\mu(x_k, u_k)$$

如果采用神经网络去拟合策略 μ 和价值 q 那么前三步就是所有的推导过程。

接下来利用LQR进行解析的求解

根据检索内容，针对确定性策略下的动作值函数 $q_\mu(x_k, u_k)$ 对控制输入 u_k 的梯度推导如下：

1. 动作值函数的定义

在确定性策略 $u_k = \mu(x_k)$ 下，动作值函数 $q_\mu(x_k, u_k)$ 定义为从状态 x_k 和输入 u_k 开始的期望累积奖励：

$$q_\mu(x_k, u_k) = r_k + \gamma v_\mu(x_{k+1}),$$

其中：

- $r_k = r(x_k, u_k)$ 是即时奖励函数，
- γ 是折扣因子，
- $v_\mu(x_{k+1})$ 是后续状态 x_{k+1} 的状态值函数。

状态转移方程为：

$$x_{k+1} = f(x_k, u_k),$$

其中 f 是系统动态模型（例如线性系统 $x_{k+1} = Ax_k + Bu_k$ ）。

2. 梯度推导

对 u_k 求梯度时，需考虑 q_μ 对 u_k 的直接依赖和通过状态转移 x_{k+1} 的间接依赖：

$$\nabla_{u_k} q_\mu(x_k, u_k) = \nabla_{u_k} r_k + \gamma \nabla_{u_k} v_\mu(x_{k+1}).$$

(a) 即时奖励项的梯度

$$\nabla_{u_k} r_k = \nabla_{u_k} r(x_k, u_k).$$

若奖励函数为二次型（例如 $r_k = x_k^\top Q x_k + u_k^\top R u_k$ ），则：

$$\nabla_{u_k} r_k = 2R u_k \quad (\text{假设 } R \text{ 对称}).$$

(b) 状态值函数项的梯度

由链式法则：

$$\nabla_{u_k} v_\mu(x_{k+1}) = \underbrace{\nabla_{x_{k+1}} v_\mu(x_{k+1})}_{\text{状态值梯度}} \cdot \underbrace{\nabla_{u_k} f(x_k, u_k)}_{\text{动态模型梯度}}.$$

- **动态模型梯度：**对线性系统 $x_{k+1} = Ax_k + Bu_k$ ，有：

$$\nabla_{u_k} f(x_k, u_k) = B^\top \quad (\text{雅可比矩阵}).$$

- **状态值梯度**：在最优控制中， $v_\mu(x_{k+1})$ 可表示为二次型 $\frac{1}{2}x_{k+1}^\top P x_{k+1}$ ，其中 P 是Riccati方程的解：

$$\nabla_{x_{k+1}} v_\mu(x_{k+1}) = P x_{k+1}.$$

(c) 合并结果

代入链式法则：

$$\nabla_{u_k} v_\mu(x_{k+1}) = (P x_{k+1})^\top B = x_{k+1}^\top P^\top B.$$

若 P 对称（常见于控制问题,通常会人为给定一个对称的R和Q导致了P也是对称的，详细可以让deepseek推导一下），则 $P^\top = P$ ，简化为：

$$\nabla_{u_k} v_\mu(x_{k+1}) = x_{k+1}^\top P B.$$

3. 最终梯度表达式

结合所有项：

$$\nabla_{u_k} q_\mu(x_k, u_k) = \nabla_{u_k} r_k + \gamma (x_{k+1}^\top P B).$$

代入状态转移方程 $x_{k+1} = A x_k + B u_k$ ：

$$\nabla_{u_k} q_\mu(x_k, u_k) = \nabla_{u_k} r_k + \gamma ((A x_k + B u_k)^\top P B).$$

若奖励函数为二次型 $r_k = x_k^\top Q x_k + u_k^\top R u_k$ ，则：

$$\nabla_{u_k} r_k = 2 R u_k,$$

$$\text{且： } (A x_k + B u_k)^\top P B = x_k^\top A^\top P B + u_k^\top B^\top P B.$$

$$\text{因此： } \nabla_{u_k} q_\mu(x_k, u_k) = 2 R u_k + \gamma (B^\top P A x_k + B^\top P B u_k).$$

简化形式

若 $\gamma = 1$ （无折扣）且 P 对称：

$$\nabla_{u_k} q_\mu(x_k, u_k) = 2 B^\top P A x_k + 2(R + B^\top P B) u_k.$$

4. 关键依据

1. 贝尔曼方程关系： $q_\mu(x_k, u_k) = r_k + \gamma v_\mu(x_{k+1})$ 。
2. 状态值梯度： $\nabla_x v_\mu(x) = P x$ （来自Riccati方程解）。
3. 动态模型梯度：对线性系统 $\nabla_{u_k} f(x_k, u_k) = B^\top$ 。
4. 奖励函数梯度：二次型奖励的梯度为 $\nabla_{u_k} r_k = 2 R u_k$ 。

整个过程中看懂 $v_\mu(x_{k+1}) = q_\mu(x_{k+1}, u_{k+1}^{opt}) = x_{k+1}^\top P x_{k+1}$ 至关重要

也可以从后往前看，利用动态规划的思想 参考控制之美卷2第65页的推导，更容易理解。

