

离散系统的LQR最优控制推导

从动态规划（Dynamic Programming）和贝尔曼方程（Bellman Equation)的起点开始，一步步为你推导出最优增益 K 和 Riccati 方程 P 。

这是参考控制之美的推导，更加清晰：[📖 基于动态优化思想的离散系统的LQR最优控制推导](#)

第一步：构建贝尔曼方程（最优性原理）

我们要最小化无限视角的累积代价函数：

$$J = \sum_{k=0}^{\infty} (x_k^T Q x_k + u_k^T R u_k)$$

根据理查德·贝尔曼（Richard Bellman）的最优性原理，我们可以将这个无限步的优化问题，拆解为当前步的代价加上未来所有步的最优代价。

我们定义**最优价值函数** $V(x_k)$ （**能量总和函数**）为从状态 x_k 开始，执行最优策略所产生的最小累积代价。那么，贝尔曼方程可以写为：

$$V(x_k) = \min_{u_k} \left[\underbrace{x_k^T Q x_k + u_k^T R u_k}_{\text{当前步代价}} + \underbrace{V(x_{k+1})}_{\text{下一状态的最优代价}} \right]$$

状态k是第k个状态，囊括了这个时间序列上的某一步开始所有未来的总和（因为 $V(x_{k+1})$ 的存在）为什么不写成 $V(x_k, u_k)$ ，是因为 u_k 已经通过min被确定下来（固化）了。

也可以把这个 $V(x_k, u_k)$ 全部展开来看， $V(x_k, u_k)$ 对所有的 u_k 求偏导，可以得到 $V(x_k, u_k)$ 关于 u_k 的极值，由于是因果系统，且状态空间为单步递推，所以 $V(x_k, u_k)$ 在对某一个 u_k 求偏导的时候，只会剩下几项相关的，剩余的都为0。这也是控制系统的马尔科夫性

第二步：引入二次型“猜想”

由于我们的系统是线性的（ $x_{k+1} = A_d x_k + B_d u_k$ ），且单步代价是关于状态和动作的二次型，数学上可以证明：**最优价值函数必然也是关于状态的二次型**。（直觉如此）

因此，我们假设（或者说合理猜测）引入状态反馈的最优价值函数的形式为（李亚普诺夫函数）：

$$V(x_k) = x_k^T P x_k \text{（由于没有 } u_k \text{，所以必然引入了状态反馈）}$$

（见最后一节的内容）

其中， P 是一个未知的对称正定矩阵（ $P = P^T \succ 0$ ）。我们的终极目标就是找出这个 P 是什么。

将这个假设代入贝尔曼方程：

$$x_k^T P x_k = \min_{u_k} [x_k^T Q x_k + u_k^T R u_k + x_{k+1}^T P x_{k+1}] \quad (1)$$

第三步：展开并求解最优动作 u_k^*

现在，我们把线性系统动态 $x_{k+1} = A_d x_k + B_d u_k$ 代入到上面的方程右侧：

$$x_{k+1}^T P x_{k+1} = (A_d x_k + B_d u_k)^T P (A_d x_k + B_d u_k)$$

利用矩阵转置性质 $(X + Y)^T = X^T + Y^T$ 以及 $(XY)^T = Y^T X^T$ ，将其展开：

$$x_{k+1}^T P x_{k+1} = x_k^T A_d^T P A_d x_k + x_k^T A_d^T P B_d u_k + u_k^T B_d^T P A_d x_k + u_k^T B_d^T P B_d u_k$$

这里有一个关键的矩阵代数技巧：

因为 $x_{k+1}^T P x_{k+1}$ 是一个标量（一个数字，不是矩阵），所以它展开后的每一项也都是标量。标量的转置等于它本身。

观察中间两项： $(x_k^T A_d^T P B_d u_k)^T = u_k^T B_d^T P^T A_d x_k$ 。因为 P 是对称的（ $P = P^T$ ），所以这两项是完全相等的！我们可以合并它们：

$$x_{k+1}^T P x_{k+1} = x_k^T A_d^T P A_d x_k + 2u_k^T B_d^T P A_d x_k + u_k^T B_d^T P B_d u_k$$

现在，把这个展开式放回式(1)我们要最小化的括号里（记作函数 J_{step} ）：

$$J_{step} = x_k^T Q x_k + u_k^T R u_k + x_k^T A_d^T P A_d x_k + 2u_k^T B_d^T P A_d x_k + u_k^T B_d^T P B_d u_k$$

将包含 u_k 的项和只包含 x_k 的项分别合并归类：

$$J_{step} = u_k^T (R + B_d^T P B_d) u_k + 2u_k^T (B_d^T P A_d) x_k + x_k^T (Q + A_d^T P A_d) x_k$$

寻找最优的 u_k ：

这是一个关于 u_k 的开口向上的二次多项式（因为 $R \succ 0$ 且 $P \succ 0$ ）。要找到使它最小的 u_k ，我们只需要对 u_k 求偏导，并令导数为零：

$$\frac{\partial J_{step}}{\partial u_k} = 2(R + B_d^T P B_d) u_k + 2B_d^T P A_d x_k = 0$$

解这个关于 u_k 的方程，把 u_k 留在左边：

$$(R + B_d^T P B_d) u_k = -B_d^T P A_d x_k$$

$$u_k^* = -(R + B_d^T P B_d)^{-1} B_d^T P A_d x_k$$

这就是 LQR 的最优控制律！我们通常定义前面的矩阵为反馈增益 K ：

$$K = (R + B_d^T P B_d)^{-1} B_d^T P A_d$$

所以 $u_k^* = -K x_k$ 。

此时我们还要求解矩阵 P 才能知道 K

第四步：推导 Riccati 方程

我们已经找到了最优动作 u_k^* ，但这依赖于未知的矩阵 P 。怎么求 P 呢？

我们只需把求得的最优动作 u_k^* 代回最初的贝尔曼方程中：

$$x_k^T P x_k = J_{step}(u_k^*)$$

$$x_k^T P x_k = (u_k^*)^T (R + B_d^T P B_d) u_k^* + 2(u_k^*)^T B_d^T P A_d x_k + x_k^T (Q + A_d^T P A_d) x_k$$

观察第一项，我们将前面推导出的 $(R + B_d^T P B_d) u_k^* = -B_d^T P A_d x_k$ 替换进去：

$$\text{第一项} = (u_k^*)^T [-B_d^T P A_d x_k] = -(u_k^*)^T B_d^T P A_d x_k$$

把第一项和第二项加起来：

$$-(u_k^*)^T B_d^T P A_d x_k + 2(u_k^*)^T B_d^T P A_d x_k = (u_k^*)^T B_d^T P A_d x_k$$

现在，把 $u_k^* = -(R + B_d^T P B_d)^{-1} B_d^T P A_d x_k$ 完整代入这个剩余的项：

$$\begin{aligned} & [-(R + B_d^T P B_d)^{-1} B_d^T P A_d x_k]^T B_d^T P A_d x_k \\ &= -x_k^T A_d^T P B_d (R + B_d^T P B_d)^{-1} B_d^T P A_d x_k \end{aligned}$$

把所有部分拼凑回贝尔曼方程：

$$x_k^T P x_k = x_k^T (Q + A_d^T P A_d) x_k - x_k^T A_d^T P B_d (R + B_d^T P B_d)^{-1} B_d^T P A_d x_k$$

提取公因式 x_k^T 和 x_k ：

$$x_k^T P x_k = x_k^T [Q + A_d^T P A_d - A_d^T P B_d (R + B_d^T P B_d)^{-1} B_d^T P A_d] x_k$$

由于这个等式必须对任意的系统状态 x_k 都成立，那么两边的中间矩阵必定完全相等。于是，我们得到了大名鼎鼎的离散代数 Riccati 方程（DARE）：

$$P = Q + A_d^T P A_d - A_d^T P B_d (R + B_d^T P B_d)^{-1} B_d^T P A_d$$

这个，典型的自举方程，可以写成自举形式迭代求解！

$$P_{k+1} = Q + A_d^T P_k A_d - A_d^T P_k B_d (R + B_d^T P_k B_d)^{-1} B_d^T P_k A_d$$

总结脉络

1. 猜想最优代价是二次型（也是李亚普诺夫值函数）： $V(x) = x^T P x$
2. 代入系统的演化式，对未来的控制量 u 求导寻找最小值，得出**最优增益** K （它依赖于 P ）。
3. 把最优的 u 代回原方程，消除掉 u ，只留下关于状态 x 的方程，从而提取出**约束 P 的非线性矩阵方程（Riccati 方程）**。

在实际工程中，由于 Riccati 方程是非线性的，我们无法直接写出 P 的解析解，通常是通过迭代法（如值迭代 Value Iteration）在计算机中求解的。

在 LQR（以及许多能够收敛的最优控制/强化学习问题）中，最优价值函数 $V^*(x)$ 本身就是一个完美的李亚普诺夫函数！

为什么P一定是半正定的

Riccati 方程解出来的 P 之所以必然是正定（或半正定）的，我们可以从物理直觉（代价的累加）和数学代数（方程的等价变形）两个最核心的维度来把这件事彻底看透。

1. 物理直觉：代价从来不能“倒找钱”

这是最简单、也最本质的理解方式。

你还记得 P 代表什么吗？在 LQR 中， P 构成了最优价值函数：

$$V^*(x) = x^T P x$$

而这个价值函数，代表的是从当前状态 x 出发，一直到系统完全稳定，所需要花费的**总代价**。

总代价是怎么来的？是每一步的代价累加起来的：

$$J = \sum_{k=0}^{\infty} (x_k^T Q x_k + u_k^T R u_k)$$

- 我们一开始就人为设定了 $Q \succeq 0$ （状态权重矩阵半正定），所以对于任何状态偏差，惩罚 $x_k^T Q x_k \geq 0$ 。
- 我们也设定了 $R \succ 0$ （控制权重矩阵正定），所以对于任何控制输出，惩罚 $u_k^T R u_k \geq 0$ 。

既然每走一步，你都要付出**大于或等于 0** 的代价，无论你怎么走，这些非负的代价累加到无限远的未来，总和 J 绝对不可能是一个负数！

也就是说，对于任何初始状态 x ，总有：

$$V^*(x) = x^T P x \geq 0$$

在矩阵代数中，**如果对于任意向量 x ，二次型 $x^T P x$ 都大于等于 0，这就是“矩阵 P 为半正定”的严格数学定义**。系统运行不会“倒找钱”给你，所以 P 绝不可能是负定的。

2. 数学代数：Riccati 方程的隐秘等价形式

如果你觉得物理直觉不够严谨，我们直接拆解数学公式。

我们把最优控制律 $K = (R + B_d^T P B_d)^{-1} B_d^T P A_d$ 和闭环系统矩阵 $A_{cl} = A_d - B_d K$ 拿过来。

经过一番矩阵代数的移项和化简（这里省略繁琐的展开步骤），你会发现那个长得令人头皮发麻的 Riccati 方程：

$$P = Q + A_d^T P A_d - A_d^T P B_d (R + B_d^T P B_d)^{-1} B_d^T P A_d$$

竟然可以等价重写为下面这个极其优美的形式（闭环李亚普诺夫方程）：

$$P = A_{cl}^T P A_{cl} + K^T R K + Q$$

你看这个等式的右边：

1. Q ：我们一开始就规定了它是半正定的（ $\succeq 0$ ）。
2. $K^T R K$ ：因为 R 是正定的，一个矩阵乘上正定矩阵再乘上它的转置，结果必然是半正定的（ $\succeq 0$ ）。

如果闭环系统是稳定的（ A_{cl} 收敛），我们可以把这个等式无限次迭代展开，最终 P 可以写成一个无穷级数：

$$P = \sum_{k=0}^{\infty} (A_{cl}^T)^k (Q + K^T R K) (A_{cl})^k$$

因为 $Q + K^T R K$ 是半正定的，它被 $(A_{cl}^T)^k$ 和 $(A_{cl})^k$ 从两边“夹击”相乘后，依然是半正定的。无数个半正定矩阵加在一起，结果 P 毫无悬念，必然是半正定的！

一个怪异点：关于 u_k 的消失与“状态反馈”的因果倒置

在你的批注中，你写了两句话：

1. “为什么不写成 $V(x_k, u_k)$ ，是因为 u_k 已经通过 $\min$ 被确定下来（固化）了。”——这句话非常正确！
2. “（由于没有 u_k ，所以必然引入了状态反馈）”——这句话的因果关系有些倒置，这正是你觉得怪异的根源之一。

理清因果：

并不是“因为我们引入了状态反馈 $u = -Kx$ ，所以 V 里面没有 u ”。

真实的逻辑是：“因为我们要对 u_k 求全局最小值（ $\min_{u_k}$ ），求完极值之后， u_k 作为自变量就被消灭了，剩下的结果自然只和 x_k 有关。对于 x_{k+1} 也是如此”

举个最简单的代数例子：

定义函数 $f(x) = \min_y (x^2 + y^2 - 2xy + 3y)$

在这个括号里，有两个变量 x 和 y 。但是当你对于 y 求完导、找到最小的 y^* 并代回原式后，最终的 $f(x)$ 里面绝对不会再有 y 。此时我们发现，那个最优的 y^* 恰好是 x 的某种函数（这在控制里就叫状态反馈）。

在 RL（强化学习）的语境里：

- 括号里包含 u_k 的那一大长串，叫 Q 函数（动作价值函数）： $Q(x_k, u_k)$ 。
- 求完 $\min_{u_k}$ 之后坍缩成的结果，叫 V 函数（状态价值函数）： $V(x_k)$ 。

所以， $V(x_k) = x_k^T P x_k$ 这个假设中没有 u_k ，是因为它已经是“千帆过尽、寻找过最优解之后”的纯粹状态价值，而不是因为我们提前把反馈策略塞进去了。

稳定性视角：自动构造李雅普诺夫函数

在非线性控制中，要证明稳定性，需要费力地寻找一个李雅普诺夫函数。

对于线性系统，LQR 直接为您**生成**了一个全局最优的二次型李雅普诺夫函数： $V(x) = x^T P x$ ，并且其对应的控制器 $u = -Kx$ 能保证 $\Delta V(x) = V(x_{k+1}) - V(x_k) < 0$ 。

这意味着，LQR 设计出的控制器不仅性能最优，而且天然保证了闭环系统的全局渐近稳定性。 这是它相对于许多其他控制方法的一个巨大优势。